

文生图模型能力评测报告

—— 基于风景美学与叙事感女性人像美学的横向评测

评测对象：Midjourney V8.2、Seedream 5.0 Pro、Kling Image 3.0

评测维度：风景美学·叙事感女性人像美学

评测时间：2026 年 9 月

评测人：L

摘要

文生图模型的竞争正从"生成正确"转向"生成真实与美", 指令遵循已不足以刻画模型能力, 隐性审美、质感还原与文化理解成为新的分水岭。本报告以 Midjourney V8.2、Seedream 5.0 Pro、Kling Image 3.0 三个主流模型为对象, 通过 82 道跨场景题目, 从风景美学、叙事感女性人像美学两个维度进行系统性评测。

方法上采用"先导研究—正式研究"两阶段设计: 通用能力(25 题)作为先导研究验证评分维度并识别提示词缺陷; 风景(27 题)与人像(30 题)作为正式研究, 采用"显性指令符合度 / 美学质量"双层评分框架——准确度按 1/0 分制计准确率, 美学质量按 1—5 分制评分(差异 <0.2 分视为同一水平)。评分依据明确锚点, 低分案例逐题归因。

评测结果显示三模型能力呈结构性分化: Midjourney V8.2 美学表现突出、准确执行偏弱, 画面氛围与摄影质感最强, 但风景专业风格契合度仅 20.0% (1/5)、人像景别准确率仅 48.3%; Seedream 5.0 Pro 准确执行最稳、美学均衡中上, 最接近"技术正确", 但服装造型美感偏弱; Kling Image 3.0 指令遵循尚可, 但真实质感系统性落后, 人像皮肤细节、服装造型、动态快门均低于及格线。三模型共性短板为: 景别理解不准(最高仅 62.1%)、光位混淆(自然光还原度均未超 70%)、东方风格理解分化。准确度与美学质量被证明是两个相对独立的能力维度, 须分层评价。

本报告结论基于单人评分与当前模型版本, 适用于风景与叙事感人像场景, 更多局限与多人盲评、开源基准等改进方向见第七章。

目录

摘要	1
一、评测背景与目标	3
1.1 评测背景	3
1.2 评测目标	3
1.3 评测对象与参数	3
1.4 评测范围	4
二、评测设计	5
2.1 两阶段设计：先导研究—正式研究	5
2.2 评分逻辑	5
2.3 评分口径	6
2.4 语言策略	6
2.5 生成与选择策略	6
2.6 正式研究提示词设计对先导研究的继承	7
2.7 评测执行流程	7
三、正式研究一——风景美学专项评测	8
3.1 维度设计	8
3.2 题目设计	8
3.3 结果	9
3.4 典型 Bad Case 归因	13
3.5 小结	15
四、正式研究二——叙事感女性人像美学专项评测	16
4.1 维度设计	16
4.2 题目设计	16
4.3 结果	17
4.4 典型 Bad Case 归因	21
4.5 小结	23
五、总结	25
5.1 三模型能力画像	25
5.2 准确度与美学质量的关系	25
5.3 跨专项共性短板	26
5.4 美学能力分水岭	26
六、方法论价值、局限与改进方向	28
6.1 方法论价值	28
6.2 局限性	28
6.3 结论适用边界与使用建议	29
6.4 下一版改进方向	30
附录	32

一、评测背景与目标

1.1 评测背景

文生图模型在过去两年经历了快速迭代。随着生成质量的整体提升，模型之间的竞争正在发生转移。分辨率、基础语义正确性不再是主要瓶颈，真正拉开差距的是：生成结果是否具备真实摄影质感、是否具有可识别的美学调性、是否能在特定文化与风格语境下准确表达。与此同时，国内模型与海外模型在中文理解、东方文化呈现和真实质感还原上，开始出现明显的的能力分化。

这一阶段，评测不能再以“对错”为唯一标准。评测者需要在“对不对”与“好不好”之间建立新的分析框架，才能更准确地刻画模型能力边界。

1.2 评测目标

本次评测试图回答四组问题。

第一组：显性指令执行能力。当提示词明确指定构图方式、光线类型、景别、人物特征、风格约束时，模型是否能够忠实执行，而非依赖默认生成策略？

第二组：美学质量呈现能力。模型生成结果是否在构图、光影、影调、色彩、透视等方面达到专业摄影美学水准。风景中，该能力在提示词未明确要求时评价；人像中，该能力独立评价，不依赖提示词是否明确要求。

第三组：真实质感还原能力。皮肤纹理、服装材质、环境细节、景深虚化等“真实感”维度，是否已成为模型之间差异最大的分水岭？

第四组：文化与风格理解能力。海外模型与国内模型在中国传统节日、水墨画、古典建筑等东方语境下的表现差异有多大？模型失败的原因是数据缺失、风格理解偏差，还是文化语义的空白？

这四组问题是本报告的探究方向，不是评分维度。评分维度将在各专项中另行定义。

1.3 评测对象与参数

模型	所属公司	平台	参数设置
Midjourney V8.2	Midjourney Inc.	网页版	RAW 模式，风格化 100，HD
Seedream 5.0 Pro	字节跳动	网页版	2K 输出

Kling Image 3.0	快手	网页版	2K 输出
-----------------	----	-----	-------


关于 Midjourney V8.2 风格化参数的说明：本次评测在确定参数时进行了小规模预实验，对比了风格化 0、50、100 三档。预实验发现，风格化 0 和 50 的生成效果明显较差，而 100 是网页版默认参数，也是正常用户在使用网页版时的默认体验。因此最终选用 100，并非为刻意拉高美学表现，而是选择一个更接近官方默认体验且生成质量稳定的设置。

1.4 评测范围

本次评测共 82 道题目，覆盖三个专项：

专项	题目数量	评分结构	定位
通用能力	25 题	单层 1—5 分制	先导研究
风景美学	27 题	准确度 + 美学质量	正式研究
叙事感女性人像美学	30 题	准确度 + 美学质量	正式研究

二、评测设计



2.1 两阶段设计：先导研究—正式研究

本次评测采用“先导研究—正式研究”两阶段设计。

先导研究以通用能力为主要内容，目的是验证评分维度是否可用、题目难度分层是否合理、跨模型对比是否可行。通过先导研究，评测者识别出写实风格约束缺失、光效词汇歧义等问题，并据此对正式研究进行修正。景别标准则在正式研究人像专项设计过程中进一步细化。

正式研究包含风景美学与叙事感女性人像美学两个专项。正式研究在先导研究的基础上，采用更成熟的“显性指令符合度 / 美学质量”双层评分逻辑，维度划分更细，评分标准更明确，样本量更充分。

这一设计使评测方法本身具有演进性，而非一次性成型的静态方案。

2.2 评分逻辑

正式研究部分采用“显性指令符合度 / 美学质量”双层评分逻辑。

显性指令符合度回答：模型是否精确执行了提示词中明确写出的要求。该层只在提示词明确涉及某一要素时激活，采用 1/0 分制，结果以准确率表示。

美学质量回答：模型生成结果在视觉美学上是否达到专业水准。该层采用 1—5 分制评分，5 分为满分，3 分为及格线，2 分及以下为明显缺陷。

风景与人像在具体结构上存在差异。

风景评测：准确度与美学质量在同一组维度上呈互补关系。提示词明确要求某一视觉要素时，该维度进入准确度评分；未明确要求时，进入美学质量评分。例如，提示词写“三分法构图”时，构图维度评准确度；未写时，构图维度评美学质量。

人像评测：准确度与美学质量分为两套独立维度。准确度维度仅在提示词明确涉及对应要素时激活，美学质量维度独立评分，不依赖准确度是否激活。例如，无论提示词是否写“皮肤真实”，皮肤细节维度都会评美学质量。

风景与人像采用不同评分结构，不是设计偏好，而是由两类题材的评分对象属性决定的。风景维度大多可以客观判断“对不对”，因此适合在同一组维度上互补评分；人像的很多美学维度无法用对错衡量，只能评“好不好”，因此必须将准确度与美学质量拆成两套独立维度。

美学质量评分由单人依据统一锚点完成，内部排序一致性高，但受个人审美尺度与宽严偏好影响，绝对分值与多人评分共识均值相比存在约 ± 0.3 分的系统性偏差空间。因此模型间分差小于 0.3 分的维度，不判定为显著能力差异，仅作相对参考。

2.3 评分口径

本报告共采用三套评分口径：

阶段/类型	评分方式	结果表示
通用能力（先导研究）	单层 1—5 分制	均分
风景与人像准确度	1/0 分制	准确率（%）
风景与人像美学质量	1—5 分制	均分

2.4 语言策略

为保证各模型在自身最擅长的语言环境下被测试，本次评测采用“各模型最适语言”策略：Seedream 5.0 Pro、Kling Image 3.0 使用中文提示词；Midjourney V8.2 使用英文提示词。目的是测试各模型在自身最优语言条件下的能力上限，而非跨语言泛化能力。跨语言对比不在本次评测范围内。

2.5 生成与选择策略

模型	生成数量	选择方式	画幅
Midjourney V8.2	4 张	选最优 1 张	16:9
Seedream 5.0 Pro	3 张	选最优 1 张	16:9
Kling Image 3.0	3 张	选最优 1 张	16:9

需要说明的是，“最优一张”是只按指令符合度优先、美学其次，策略反映的是模型能力上限，而非生成稳定性。生成稳定性的评测需另设方法，本文不做展开。

2.6 正式研究提示词设计对先导研究的继承

正式研究之前，先以 25 道通用能力题目开展了先导研究。题库按难度分为 L1（原子能力层）、L2（组合能力层）、L3（综合压力层）三层，从指令遵循度、物理真实感、美学质量、风格一致性、文化合理性、安全合规性六个维度进行 1—5 分制探索性评分（完整方法、题库、逐题评分与统计见附录 1-1 至 1-4）。先导研究的结果不作为最终结论，仅作为正式研究的方法论输入。

先导研究的核心发现是：三个模型在基础能力上已出现分化。Seedream 5.0 Pro 各维度接近满分、表现最均衡；Kling Image 3.0 指令遵循较高，但物理真实感与美学质量明显偏低；Midjourney V8.2 文化合理性仅为 3.00、风格一致性 3.40，在东方文化与风格理解上存在明显短板。复杂人物场景下的物理真实感（如手部精细交互）是三模型共同的薄弱点。

更重要的是，先导研究暴露的问题直接修正了正式研究的设计：

第一，写实风格约束的统一。先导研究阶段发现，部分人物类题目未显式声明“写实”，导致 Midjourney V8.2 在复杂人物场景中生成漫画风格，物理真实感评分失效。因此，正式研究的人像专项提示词统一加入“写实摄影，真实皮肤质感，非动漫”。风景专项未加该约束，原因有二：一是自然风光题材默认即写实方向，发生风格漂移的概率极低；二是风景题库中包含水墨画、日系清新等风格题，统一加写实约束会与风格准确度评测直接冲突。实际评测中，风景题未出现风格漂移，证明该设计成立。

第二，光效词汇的明确化。先导研究阶段发现，模型对“逆光”“侧逆光”等光位理解不稳定，易混淆。正式研究阶段，人像提示词中对光效的描述更多样和明确，例如“侧逆光从窗外照入”“逆光从窗外照入”，以减少光位理解的歧义。

此外，先导研究还提示正式研究需要在真实质感维度上给予更大权重。这直接影响了人像专项的维度设计，使皮肤细节、服装造型、环境细节等真实质感维度成为独立评分项。

2.7 评测执行流程

- （1）根据专项维度设计提示词，覆盖目标能力点；
- （2）各模型按统一画幅生成多张，选取最优一张进入评分；
- （3）先评准确度，再评美学质量；

- (4) 对低分案例进行归因分析；
- (5) 统计均分，绘制对比图表，形成能力画像。

三、正式研究一——风景美学专项评测

本部分评测方法见附录 2-1，完整题目（中、英文提示词）见附录 2-2，生成图片、评分及 bad case 分析见附录 2-3，均分及可视化见附录 2-4。

3.1 维度设计

风景美学专项共设置 9 个评分维度，其中 7 个为核心维度，2 个为条件激活维度。

核心维度（7 个）：构图与视觉平衡、层次感与空间深度、光线、影调、色彩、细节自然度、景深。这 7 个维度始终参与评分，但评分性质由提示词决定：提示词明确要求某一视觉要素时，该维度进入准确度评分（1/0）；提示词未明确要求时，该维度进入美学质量评分（1—5）。

条件激活维度（2 个）：专业风格符合度、文化合理性。仅当提示词明确指定风格或涉及人文元素时，这两个维度才进入准确度评分；若提示词未涉及，则记为 N/A，不参与任何均分。

因此，风景评测的准确度与美学质量在 7 个核心维度上呈互补关系：同一维度要么评准确度，要么评美学质量，不会同时评分。专业风格符合度与文化合理性则只评准确度，不评美学质量。

3.2 题目设计

3.2.1 覆盖变量

风景专项共 27 题，覆盖以下变量：

变量类型	覆盖内容
场景类型	海边、湖面、山谷、森林、田野、沙漠、城市、古镇、寺庙、梯田等
季节与时间	春夏秋冬、清晨、黄昏、夜晚、蓝调时刻
光线条件	顺光、侧光、逆光、侧逆光、柔光、丁达尔效应
景别	远景、全景、中景、近景、微距特写
风格指定	电影感、蓝调、日系清新、水墨画意境等

文化元素	江南水乡、京都街道、欧洲小镇、明孝陵、故宫、黄山等
------	---------------------------

3.2.2 评测维度及数量设计

3.2.2.1 准确度

维度	构图/视觉平衡	层次感/空间深度	光线	影调	色彩	细节自然度	景深	专业风格契合度	文化合理性
题目数量	10	9	13	8	8	5	4	5	5

3.2.2.2 美学质量

维度	构图/视觉平衡	层次感/空间深度	光线	影调	色彩	细节自然度	景深
题目数量	17	18	12	16	14	20	21

风景提示词未统一加入“写实摄影”约束。原因已在 2.6 中说明：自然风光题材默认即写实方向，发生风格漂移的概率极低；同时题库中包含水墨画、日系清新等风格题，统一加写实约束会与风格准确度评测冲突。实际评测中，风景题未出现风格漂移，证明该设计成立。

3.3 结果

3.3.1 准确度

3.3.1.1 各模型准确度均分

模型	构图/视觉平衡	层次感/空间深度	光线	影调	色彩	细节自然度	景深	专业风格契合度	文化合理性
Midjourney	90.0%	100.0%	92.3%	87.5%	100.0%	100.0%	100.0%	20.0%	100.0%
Seedream	100.0%	100.0%	100.0%	100.0%	100.0%	100.0%	100.0%	100.0%	100.0%
Kling	100.0%	100.0%	92.3%	87.5%	100.0%	60.0%	75.0%	100.0%	100.0%



图 1 三大模型风景准确度对比柱状图




图 2 三大模型风景准确度对比雷达图

3.3.1.2 各模型准确度表现

风景准确度整体排序为：**Seedream 5.0 Pro > Midjourney V8.2 ≈ Kling Image 3.0**。

Midjourney V8.2 在大多数核心维度上与 Seedream 5.0 Pro 持平，最大失分点是专业风格契合度，准确率仅为 20%（1/5）。蓝调、日系清新、水墨画等风格题均出现执行失败，说明其对风格指令的理解仍不稳定，容易以默认美学替代用户指定的风格。除风格维度外，光线和影调准确率分别为 92.3% 和 87.5%，也存在少量失分，主要体现在光源方向控制和对比度控制方面。

Seedream 5.0 Pro 在准确度上表现最稳定。构图/视觉平衡、层次感/空间深度、光线、影调、色彩、细节自然度、景深、专业风格契合度、文化合理性九个维度均未出现执行失败，说明其对风景类提示词中显性指令的执行能力最可

靠，尤其在一些具有明确风格或文化要求的题目上仍能保持稳定输出。

Kling Image 3.0 在多数准确度维度上与 Seedream 5.0 Pro、Midjourney V8.2 基本持平，但细节自然度准确率仅为 60.0%，景深准确率仅为 75.0%，均为三模型中最低。雪山纹理、水面波纹、树叶等自然纹理多次出现明显失真，说明其在真实纹理生成上的准确执行能力存在明显短板。光线和影调准确率同样为 92.3% 和 87.5%，与 Midjourney V8.2 持平。光线失分点在于水面反光不符合真实物理情况、对比度不能满足提示词要求。

3.3.2 美学质量

3.3.2.1 各模型美学质量均分

模型	构图/视觉平衡	层次感/空间深度	光线	影调	色彩	细节自然度	景深
Midjourney	4.65	4.94	5.00	4.81	4.79	4.85	5.00
Seedream	4.65	4.89	4.83	4.50	4.86	4.90	4.86
Kling	4.41	4.61	4.67	4.06	3.86	4.05	4.10



图 3 三大模型风景美学质量对比柱状图




图 4 三大模型风景美学质量对比雷达图

3.3.2.2 各模型美学质量分析

风景美学质量整体排序为：**Midjourney V8.2 > Seedream 5.0 Pro > Kling Image 3.0**。

Midjourney V8.2 在风景美学质量上表现最强。光线、景深均达到 5.00，樱花逆光复杂的光影生成效果接近真实，景深过渡自然。层次感/空间深度、影调、色彩、细节自然度也均处于三模型最高或接近最高水平。其自然风光画面在明暗层次、空间深度和镜头感上表现突出，摄影质感明显。但在专业风格题中，美学质量高并不能弥补风格准确度不足的问题，说明其“画得好看”与“画得对”之间存在脱节。

Seedream 5.0 Pro 在美学质量上整体稳定。构图/视觉平衡、层次感/空间深度、光线、影调、景深均介于另外两模型之间。色彩表现明显高于 Kling Image 3.0。整体来看，Seedream 5.0 Pro 在美学质量上没有明显短板，但也没有显著领先的维度。

Kling Image 3.0 在美学质量上明显偏弱。影调 4.06、色彩 3.86、细节自然度 4.05、景深 4.10，同样处于三模型最低水平。其自然风光画面在色彩和谐度、明暗层次和纹理真实感上均存在明显不足，与 Midjourney V8.2 的摄影质感和 Seedream 5.0 Pro 的均衡表现存在较大差距。色彩方面，会出现饱和度、色相、明度不和谐的问题。影调方面，过渡不佳。景深方面，体现在前景、中景、后景都过于清晰，没有适度、自然的虚化效果。景深、细节自然度、影调与色彩的低表现会导致 Kling Image 3.0 生成画面不同主体之间拼接感强，像假图。

3.3.3 共同短板与区分度

风景准确度存在一定的天花板效应。层次感与空间深度、色彩、文化合理性等维度，三模型均达到 100.0%，说明这些维度在风景题材中相对容易达成，区分度不足。真正拉开差距的是专业风格契合度、细节自然度、光线和影调四个维度。专业风格契合度是区分度最大的准确度维度。Midjourney V8.2 仅为 20.0%，而 Seedream 5.0 Pro 和 Kling Image 3.0 均达到 100.0%。这说明海外模型在东方风格和特定摄影风格的语义理解上仍有明显差距。细节自然度是另一个高区分度维度。Kling Image 3.0 仅为 60.0%，Seedream 5.0 Pro 和 Midjourney V8.2 均达到 100.0%。这说明真实纹理生成是国内部分模型与头部模型之间的主要分水岭之一。

在美学质量层面，色彩和影调是两个区分度最明显的维度。Kling Image 3.0 在色彩和影调上均明显落后，而 Midjourney V8.2 和 Seedream 5.0 Pro 在这两项上表现相对接近，说明色彩和谐度与明暗层次控制仍是风景生成模型之间拉开差距的关键能力。

3.4 典型 Bad Case 归因

案例一：Midjourney V8.2——海边人文(L-01)



题目：海边几只海鸥在天上盘旋，一个渔民老爷爷的背影位于画面右三分之一处，前景有沙滩，天空占三分之二，电影感风光摄影，蓝调风格

现象：人物位于画面中间，未按要求位于右三分之一处；整体色相偏暖色，未呈现蓝调风格。

归因：该案例同时暴露了 Midjourney V8.2 的两个问题。第一，构图指令未被执行。提示词明确要求“背影位于画面右三分之一处”，但生成结果将人物置于画面中部，说明模型在处理明确空间位置指令时仍不稳定。第二，风格语义理解出现偏差。提示词明确要求“蓝调风格”，模型却生成了暖色画面，说明其将“蓝调”泛化为普通风光色调，而非严格按蓝色主调执行。

启示：Midjourney V8.2 的自然风光美学能力很强，但当提示词包含明确构图与风格约束时，其指令遵循能力反而成为风险点。评测中不能因其美学表现好而忽略准确度问题。

建议：强化空间构图指令的响应精度；在训练数据中增加蓝调时刻的色相标注，提升风格指令执行准确率。

案例二：Seedream 5.0 Pro——野花丛远树(L-06)



题目：前景是虚化的野花丛，焦点落在远处一棵树，大光圈浅景深，背景柔美虚化，逆光

现象：构图不美观，主体（树木）被裁切在画面边缘，视觉重心失衡；层次过渡略显生硬。

归因：该题在准确度上并未失分，说明 Seedream 5.0 Pro 正确执行了“前景虚化、焦点落在远处一棵树”的指令。问题出在美学质量中的构图维度。模型在自由构图时，未将主体放在合理的视觉位置，导致树木被裁切、画面失重。这属于构图美学判断能力不足，而非指令理解错误。对于未明确指定构图方式的题目，模型倾向于生成“技术上正确但审美上平庸或失衡”的结果。

启示：Seedream 5.0 Pro 在风景准确度上表现最稳，但自由构图时的审美稳定性仍有提升空间。这也说明准确度高不等于美学质量高，两者需要分开评价。

建议：引入构图美学先验，避免主体贴边或过度裁切；训练数据中增加主体位置、留白与视觉平衡的优质样本。

案例三：Kling Image 3.0——高山草甸全景（L-05）



题目：高山草甸全景，前景野花、中景溪流、远景雪山全部清晰，小光圈、大广角风光摄影，细节丰富

现象：影调过渡差，草原与雪山拼接感强；野花呈动漫感，出现色块；黄色饱和度 and 明度偏高。

归因：Kling Image 3.0 在该题中暴露了多个维度的能力短板。细节自然度准确度为 0，雪山纹理缺失，野花被过度简化为色块，缺乏真实植物纹理；影调上，前景、中景、远景的明暗关系不统一，出现明显的“拼接感”；色彩上，黄色饱和度过高，不符合真实风光摄影的克制感。这三个问题共同指向一点：Kling Image 3.0 在多元自然风光合成时，空间、光影和纹理的真实感控制能力仍较弱。

启示：Kling Image 3.0 的基础指令遵循尚可，但一旦进入高细节、多层次的真实风光场景，其生成质量会明显下降。真实质感是 Kling Image 3.0 与 Midjourney V8.2、Seedream 5.0 Pro 之间的主要差距。

建议：增加高分辨率真实风光摄影训练样本，尤其强化草地、雪山、野花等自然纹理；在色彩训练中约束饱和度范围，避免过度鲜艳；同时提升多尺度场景的影调统一性。

3.5 小结

Midjourney V8.2 的核心特征是美学质量突出，但风格执行不稳。影调、景深、层次感/空间深度、构图/视觉平衡等维度均表现优异，自然风光画面在摄影质感上最强。但专业风格契合度严重偏低，说明其在需要遵循明确风格指令时存在明显能力边界。

Seedream 5.0 Pro 的核心特征是准确度最稳、美学均衡。在风景评测中，Seedream 5.0 Pro 是执行提示词最稳的模型，且在美学质量上无明显短板。其自然风光画面在色彩、细节、光线上均有较好表现，整体能力最均衡。

Kling Image 3.0 的核心特征是基础准确度尚可，但真实纹理与色彩影调落后。构图、色彩、景深、文化合理性等维度准确度不低，但细节自然度严重偏低。美学质量中色彩、影调明显偏弱，画面在真实风光质感和色彩和谐度上仍有较大提升空间。

风景准确度方面，各个模型达成效果较好，专业风格契合度、细节自然度、光线和影调是拉开模型表现力的四个维度。在美学质量层面，细节自然度、色彩和影调是三个区分度最明显的维度。

四、正式研究二——叙事感女性人像美学专项评测

本部分评测方法见附录 3-1，完整题目（中文及英文提示词）见附录 3-2，生成图片、评分见附录 3-3，bad case 分析、均分及可视化见附录 3-4。

4.1 维度设计

叙事感女性人像美学专项采用准确度与美学质量两套独立维度。

准确度维度（7 个）：场景/元素/服装、人物特征、景别、构图与机位、自然光还原度、视角与神态、景深与虚化。准确度维度仅在提示词明确涉及对应要素时激活，采用 1/0 分制评分，结果以准确率表示。

美学质量维度（12 个）：构图与机位、层次感与空间深度、色彩、光影质量、影调、景深与虚化质量、视角神态与叙事氛围、人物与环境融合度、皮肤细节与身体结构自然度、服装与造型美学、环境细节自然度、动态与快门感。

其中，动态与快门感为条件激活维度，仅在画面涉及动态元素时评分，否则记为 N/A。安全合规性作为红线维度独立判断，Pass/Fail，不参与均分。

人像专项之所以将准确度与美学质量拆分为两套独立维度，是因为人像的很多美学表现无法用对错衡量。皮肤质感、服装造型、情绪叙事、神态自然度等，只能评“好不好”，不能评“对不对”。因此，美学质量维度不依赖准确度是否激活，独立评分。

4.2 题目设计

人像专项共 30 题，以叙事感女性人像为核心，覆盖以下变量：

4.2.1 覆盖变量

变量类型	覆盖内容
年龄	18 岁、28 岁、38 岁、48 岁
性别	女性为主，保留少量男性样本
场景	火车、窗边、庭院、园林、田野、芦苇荡、水边、树林、教室、草地等
光线	侧光、逆光、侧逆光、柔光、蓝调时刻
景别	特写、半身、全身、大景

构图与机位	三分法、居中、俯拍、平视、低角度
情绪与神态	安静、温柔、伤感、疏离、放空、回眸、低头等
动态元素	奔跑、行走、风吹发丝、裙摆扬起、伸手触水等

本次人像评测均基于专业摄影美学框架，所有提示词与生成内容均为正常艺术创作场景，无低俗、性化或不当引导内容。

4.2.2 评测维度及数量设计

4.2.2.1 准确度

维度	场景/元素/服装	人物特征	景别	构图/机位	自然光还原度	视角/神态	景深/虚化
题目数量	30	30	29	29	30	30	16

4.2.2.2 美学质量

维度	构图/机位	层次感/空间深度	色彩	光影质量	影调	景深/虚化质量	神态/叙事氛围	人物与环境融合度	皮肤细节/身体结构自然度	服装/造型美学	环境细节自然度	动态/快门感
题目数量	30	30	30	29	30	30	30	30	30	29	29	4

提示词统一加入“写实摄影，真实皮肤质感，非动漫”约束，以防止女性人物主体发生动漫化、插画化漂移。光效描述更明确，如“侧逆光从窗外照入”“逆光从窗外照入”。

4.3 结果

4.3.1 准确度

4.3.1.1 准确度均分

模型	场景/元素/服装	人物特征	景别	构图与机位	自然光还原度	视角/神态	景深/虚化
Midjourney	86.7%	100.0%	48.3%	75.9%	66.7%	66.7%	100.0%
Seedream	93.3%	100.0%	62.1%	89.7%	70.0%	90.0%	100.0%
Kling	90.0%	90.0%	58.6%	86.2%	66.7%	80.0%	100.0%

4.3.1.2 准确度分析




图 5 三大模型人像准确度对比柱状图




图 6 三大模型人像准确度对比雷达图

人像准确度整体排序为：**Seedream 5.0 Pro > Kling Image 3.0 > Midjourney V8.2**。

Seedream 5.0 Pro 在准确度上没有明显短板。它在视角/神态、构图/机位上的准确表现领先较多，人物特征和景深/虚化均达到 100.0%，场景/元素/服装、景别、自然光还原度同样略高于另外两个模型。唯一偏低的是景别，62.1% 的准确率并不理想，但该问题在三模型中普遍存在。综合来看，Seedream 5.0 Pro 是当前人像准确度表现最稳定的模型。

Kling Image 3.0 的准确度处于中间位置，但没有特别突出的维度。人物特

征准确率为 90.0%，为三模型最低，说明其在年龄、肤色、体态等人物基础特征还原上仍不够稳定。景别准确率为 58.6%，同样偏低；自然光还原度与 Midjourney V8.2 持平，均为 66.7%。Kling Image 3.0 的问题并非某一维度显著落后，而是多个维度均未形成领先优势，整体表现相对平均。

Midjourney V8.2 的准确度问题最为明显。人物特征和景深/虚化均达到 100.0%，为三模型最高，但其余五个维度全部处于三模型最低水平。其中景别准确率仅为 48.3%，意味着超过一半的题目未按要求生成半身、全身或大景。视角/神态、自然光还原度、构图/机位、场景/元素/服装同样落在最后。Midjourney V8.2 的准确度表现呈现明显分化：个别基础能力较强，但在需要精确执行指令的维度上表现不稳定。

4.3.2 美学质量

4.3.2.1 美学质量均分



图 7 三大模型人像美学质量对比柱状图




图 8 三大模型人像美学质量对比雷达图

4.3.2.2 美学质量分析

人像美学质量整体排序为：**Midjourney V8.2 > Seedream 5.0 Pro > Kling Image 3.0**。

Midjourney V8.2 的美学优势集中在画面氛围与空间表现上。8 个维度（层次感/空间深度、色彩、光影质量、景深与虚化质量、人物与环境融合度、服装/造型美学、环境细节自然度、动态/快门感）均是最高水平，其中色彩、环境细节自然度领先明显。色彩方面，生成的图片色调和谐一致，在饱和度、色相方面控制较好。光影质量方面最优，Midjourney V8.2 在面部生成复杂光影的美感和真实感强于其他两个模型。其相对薄弱之处在于人体结构自然度、影调两项，均略低于 Seedream 5.0 Pro。人体结构自然度方面，手指、脚趾、四肢出现错误的概率较 Seedream 5.0 Pro 高。影调方面，Midjourney V8.2 在曝光方面照整体较其他模型略低，有提升空间。但整体而言，Midjourney V8.2 的画面美感与摄影质感仍为三模型中最优。


Seedream 5.0 Pro 的优势方向与 Midjourney V8.2 形成互补。影调为三模型最高，皮肤细节与身体结构自然度同样领先，说明其在明暗层次控制和人物真实质感层面表现较好。环境细节自然度与景深/虚化质量接近 Midjourney V8.2 水平。但服装与造型美学仅为 3.93，生成的服装美感度、真实感构成明显短板；色彩、光影质量、动态与快门感同样偏弱，其中动态与快门感 3.5 与 Midjourney V8.2 存在较大差距。Seedream 5.0 Pro 的整体表现偏向“技术完成度较高，但美学表现力仍有不足”。

Kling Image 3.0 在美学质量层面的表现全面偏弱，尤其是光影质量、人物

与环境质感方面。12 个美学质量维度中，有 10 个维度为三模型最低。皮肤细节与身体结构自然度 2.97、服装与造型美学 3.07、动态与快门感 3.00 均低于 3 分及格线；景深/虚化质量、光影质量、色彩、神态/叙事氛围处于 3.4 至 4.0 区间。上述结果表明，Kling Image 3.0 在真实质感、画面氛围、情绪表达等核心美学能力上尚未形成稳定表现，其问题具有系统性特征，而非单一维度的偶发失误。皮肤细节与身体结构自然度是 Kling Image 3.0 失分最集中的维度。扣分原因高度一致，主要包括“皮肤有明显塑料感、蜡像感或涂抹感，细节缺失严重”“磨皮严重、衣服质感差”“皮肤质感差”等。这说明 Kling Image 3.0 生成的人像皮肤普遍过度平滑，缺乏真实毛孔、纹理和血色感，呈现明显的 AI 渲染痕迹。该问题并非个别题目中的偶然失误，推测是训练数据中高质量真实皮肤样本不足，或美学过滤机制过度偏向“光滑”所导致的系统性缺陷。在本次评测样本中，Kling Image 3.0 生成的人像面部光影表现普遍较弱，缺乏复杂光影带来的立体感和氛围感，与 Midjourney V8.2、Seedream 5.0 Pro 存在明显差距；人物表情也较为单一，情绪表现力不足。此外，Kling Image 3.0 的服装造型和环境细节也存在类似问题。服装材质生硬、褶皱不自然、缺乏垂坠感；草地、水面等自然纹理大面积失真。这些问题共同指向其在真实质感生成能力上的整体滞后。动态/快门感维度上评分仅为 3.0，表明其在运动模糊、发丝飘动等动态表现上存在明显不足。

4.4 典型 Bad Case 归因

案例一：Midjourney V8.2——庭院侧逆光看花（P-08）



题目：春末下午，日式庭院中，一位 38 岁左右的女性侧脸，黑色低盘发，穿浅粉色和服，写实摄影，真实皮肤质感，非动漫，三分法构图，平视机位，侧逆光，她低头看手中花朵，神情温柔而略带感伤，动作很轻，半身，暖金色调，浅景深

现象：视角与神态准确度 0 分，神情未体现感伤；头部被画面边缘裁切，手指存在问题。

归因：该案例暴露了 Midjourney V8.2 在人像准确度上的一个典型问题——情绪神态执行不足。提示词要求“神情温柔而略带感伤”，但生成结果未能准确

传达这一情绪。此外，头部被裁切和手指问题属于局部结构控制不足。

启示：Midjourney V8.2 在美学质量上通常表现较好，但准确度层面的情绪执行并不稳定。这说明其强项在于整体美感，而非精确执行提示词中的细微要求。

建议：增加情绪神态相关的训练数据，提升模型对“感伤”“温柔”等细微情绪的还原能力；优化头部和手部等局部结构的生成稳定性。

案例二：Seedream 5.0 Pro——芦苇逆光背影（P-14）



题目：深秋下午，芦苇荡中，一位 48 岁左右的女性背影站在芦苇丛中，栗色波浪长发，穿米色毛衣和棕色半裙，风吹芦苇，发丝飘动，写实摄影，真实皮肤质感，非动漫，三分法构图，平视机位，逆光，全身，大景，暖金色调


现象：场景/元素/服装准确度 0 分，风向矛盾；景别准确度 0 分，生成了中景而非全身大景；自然光还原度准确度 0 分，光的方向错误，属侧光而非逆光；人物与环境融合度仅 2 分。

归因：该案例集中暴露了 Seedream 5.0 Pro 在多元素、多指令叠加场景下的准确度问题。第一，风向矛盾说明模型对“风吹芦苇”“发丝飘动”等动态与自然交互的理解不准确，芦苇和发丝的飘动方向不一致。第二，景别执行失败，提示词要求全身大景，模型生成了中景。第三，自然光还原失败，提示词要求逆光，模型生成了侧光。这些问题共同表明，当提示词包含多项显性指令时，Seedream 5.0 Pro 的执行稳定性会下降，部分指令被忽略或错误执行。

启示：Seedream 5.0 Pro 在风景准确度上表现优秀，但在人像复杂指令场景下，准确度明显下降。这说明风景和人像对指令遵循的难度不同，人像场景中变量更多，模型更容易顾此失彼。

建议：强化多指令叠加场景下的指令遵循能力；增加风向、光效等自然交互与人物结合的训练样本；优化景别和光位的联合控制。

案例三：Kling Image 3.0——俯拍少女草地坐姿（P-30）



题目：初夏下午，俯拍机位，一位 18 岁左右的少女坐在草地上，黑色长发披肩，穿白色连衣裙，腿上放着一本翻开的书，脚边有一顶草帽，写实摄影，真实皮肤质感，非动漫，居中构图，低头翻看一本书，柔光，半身，浅景深，清新氛围

现象：景别准确度 0 分，生成了全身而非半身；皮肤细节 2 分，皮肤过于光滑，衣物对比度太低、纹理太少；服装与造型美学 2 分，材质生硬、褶皱差；环境细节自然度 2 分，草地纹理严重失真；景深与虚化质量 2 分，景深过渡混乱。

归因：该案例集中暴露了 Kling Image 3.0 在真实质感上的系统性问题。第一，景别执行错误，提示词要求半身，模型生成了全身，说明其俯拍场景下的景别控制不稳定。第二，皮肤质感差，皮肤被过度磨皮，缺乏真实纹理，且皮肤过亮，不符合真实物理场景。第三，服装材质生硬，褶皱不自然，缺乏真实织物的垂坠感。第四，草地纹理严重失真，大面积涂抹感明显。第五，景深过渡混乱，虚化逻辑不统一。这些问题共同指向 Kling Image 3.0 在“真实质感”维度上的能力短板。

启示：Kling Image 3.0 的指令遵循基础尚可，但真实质感是当前最主要的能力瓶颈。皮肤、服装、环境、景深等多个维度同时出现问题，说明这不是单题偶然失误，而是系统性的生成能力不足。

建议：减少皮肤过度平滑处理，补充真实皮肤纹理训练样本；增加草地、服装等自然材质的高质量数据；强化景深与空间距离的一致性学习。

4.5 小结

整体而言，景别和自然光还原度是最稳定、最明确的共同短板。景别方面，三个模型均处于较低水平，为 48.3%~62.1%。“半身/全身/大景”的边界容易被模型混淆，导致取景范围与提示词要求不一致，其中，Midjourney V8.2 的问题最为严重。光线方面是三模型共同的第二短板。自然光还原度的准确性方面，Midjourney V8.2 为 66.7%，Seedream 5.0 Pro 为 70.0%，Kling Image 3.0 为 66.7%，三模型均未突破 70%。主要问题是模型未能按照提示词指令执行，逆光、侧光、侧逆光等光位容易混淆。光效表述明确化后问题依旧，说明短板源

于模型光位理解能力，而非提示词表述。但 Midjourney V8.2 的光影质量远高于 Kling Image 3.0，主要体现在面部生成复杂光影，塑造有“氛围感”的画面效果，而这是 Kling Image 3.0 的明显短板。

Midjourney V8.2 的核心特征是美学质量突出，但准确度执行不稳。美学质量层面，Midjourney V8.2 在色彩、服装、层次感、人物融合、环境细节等维度上均明显领先，画面氛围和摄影质感最强。但准确度层面，景别准确率仅 48.3%，超过一半的题目未按要求生成，视角/神态、自然光还原度、构图/机位也均为三模型最低。Midjourney V8.2 的能力画像呈明显的“美感强、执行弱”特征。

Seedream 5.0 Pro 的核心特征是准确度强、美学质量中上，但复杂姿态和服装造型是薄弱点。准确度层面，Seedream 5.0 Pro 在所有七个维度上均没有明显短板，是三模型中执行最稳定的模型。美学质量层面，影调和皮肤细节表现最好，但服装造型美感偏弱，款式不出彩、褶皱生硬、材质垂坠感一般。此外，在坐姿、蹲姿等复杂姿态下，Seedream 5.0 Pro 出现四肢结构错误，说明其身体结构控制仍不够稳定。

Kling Image 3.0 的核心特征是基础能力尚可，但真实质感系统性落后。准确度层面，Kling Image 3.0 处于中间位置，没有特别突出的强项。美学质量层面，12 个维度中有 10 个为三模型最低，皮肤细节、服装造型、动态快门均低于及格线。Kling Image 3.0 的问题不是某一个维度的偶发失误，而是皮肤、服装、环境、动态等多个真实质感相关维度整体偏弱，属于底层生成能力的系统性不足。

五、总结

5.1 三模型能力画像

综合通用能力、风景美学、叙事感女性人像美学三个专项的结果，三个模型的能力差异呈现稳定且一致的结构性分化。

Midjourney V8.2 的核心特征是美学表现突出、准确执行偏弱。

Midjourney V8.2 在美学质量上优势明显。风景中，光线、景深均达到 5.00，构图/视觉平衡、层次感/空间深度、影调同样处于领先水平；人像中，色彩、光影质量、服装造型、人物与环境融合、环境细节自然度、动态与快门感均高于另外两个模型，画面氛围和摄影质感最强。但准确度层面，Midjourney V8.2 的问题较为突出。风景中，专业风格契合度准确率仅为 20.0%；人像中，景别准确率仅为 48.3%。其能力画像呈现明显的“美感强、执行弱”特征：在自由生成时表现优异，但在需要严格遵循提示词指令时，稳定性和准确性明显不足。

Seedream 5.0 Pro 的核心特征是均衡与可靠。

在三个专项中，Seedream 5.0 Pro 均未出现明显的能力塌陷。风景准确度中，其所有维度执行均为最优；人像准确度中，其综合表现同样最强。人像美学质量层面，Seedream 5.0 Pro 在影调和皮肤细节上表现突出，但色彩、服装/造型美学、动态与快门感与 Midjourney V8.2 有一定差距。总体来看，Seedream 5.0 Pro 是当前三个模型中最接近“技术正确”的一个，准确执行能力最强，美学表现中上，但尚未形成显著的美学风格优势。

Kling Image 3.0 的核心特征是基础执行尚可、真实质感系统性落后。

Kling Image 3.0 在准确度层面并非全面落后。人像准确度处于三模型中间水平，景深/虚化准确率也达到 100.0%。但美学质量层面，Kling Image 3.0 的问题具有明显的系统性。人像美学质量中，12 个维度有 10 个为三模型最低，皮肤细节与身体结构自然度、服装与造型美学、动态与快门感，均为低分。风景美学中，影调、色彩，也显著低于另外两个模型。Kling Image 3.0 的主要问题不在“能不能听懂指令”，而在“听懂之后能不能生成具有真实质感和美学质量的画面”。

5.2 准确度与美学质量的关系

三个专项的结果共同指向一个关键结论：**准确度与美学质量是两个相对独立的能力维度，不能互相替代，也不能用一个维度的表现推断另一个维度。**

Midjourney V8.2 是最典型的例子。它在美学质量上表现最强，但在准确度

上却存在明显短板。风景专业风格契合度准确率仅 20.0%，人像景别准确率仅 48.3%，与其在美学质量上的高分形成明显反差。这说明 Midjourney V8.2 擅长“生成好看的画面”，但当提示词包含明确的构图、风格、景别等指令时，其执行能力并不稳定。

Kling Image 3.0 的情况再次证明两者不可混为一谈。它在指令遵循、文化合理性等准确度维度上并不差，但美学质量中的真实质感维度全面偏低。即使准确执行了场景、构图、光线等指令，生成结果仍可能因皮肤塑料感、服装生硬、环境失真而缺乏真实感。

因此，评测文生图模型时，不能只看总分，也不能只评“好不好”而忽略“对不对”。准确度和美学质量需要分层评价，才能准确刻画模型的能力结构。

5.3 跨专项共性短板

从三个专项的结果看，当前文生图模型存在三个较为稳定的共性短板。

第一，景别理解不准。

人像专项中，景别是三个模型准确度最低的维度。半身、全身、大景的边界尤其容易混淆。总体来看，模型对取景范围和空间边界的语义理解仍不够精确，是当前文生图模型最普遍的执行短板。

第二，光位理解与执行不稳。

人像专项中，自然光还原度是三模型的共同弱项，评分均未突破 70%。逆光、侧光、侧逆光等光位常被模型混淆，生成结果与提示词要求不一致。风景专项中，光线准确度虽然较高，但在逆光星芒、丁达尔效应等特殊光学现象上仍出现执行失败。模型对光的方向、轮廓光和明暗分界的控制尚未达到稳定水平，这一短板在需要精确光效的人像场景中尤为明显。

第三，东方风格与文化的理解存在分化。

风景专业风格契合度中，Midjourney V8.2 也远低于其他模型，在水墨画、日系清新等风格上多次执行失败。Kling Image 3.0 虽然文化合理性较高，但在水墨画风格上出现“墨线勾边+彩块填充”的泛化问题。Seedream 5.0 Pro 在东方风格与文化题目上表现相对最稳，说明国内模型在东方语境理解上整体优于海外模型，但仍存在风格泛化的风险。

5.4 美学能力分水岭

风景专项中，细节自然度成为 Kling Image 3.0 与另外两个模型之间的主要分水岭。Kling Image 3.0 雪山纹理、水面波纹、树叶等自然纹理存在明显失真，而 Seedream 5.0 Pro 和 Midjourney V8.2 在该维度上表现远超 Kling Image

3.0。

人像专项中，真实质感维度的分化更加明显。光影质量、皮肤细节与身体结构自然度、服装与造型美学、环境细节自然度、动态/快门感五个维度，是三个模型间差距最大的维度。

这说明，真实质感已经取代基础语义正确性，成为当前文生图模型竞争的核心。模型能否从“画得对”跨越到“画得真”，将决定其在下一阶段竞争中的位置。对于 Kling Image 3.0 而言，皮肤、服装、环境纹理和动态表现的系统性落后，是其当前最需要优先解决的能力缺口。

六、方法论价值、局限与改进方向

6.1 方法论价值

本次评测在方法设计上形成了几个可复用的核心机制。

第一，显性指令符合度与美学质量分离。

评测将“是否执行指令”与“生成结果是否具有美学质量”作为两个独立层面评价，避免了传统评测中“没做对”与“做得不好”混为一谈的问题。这一设计使模型的能力结构能够被更准确地识别，尤其避免了因美学质量高而掩盖准确度不足，或因准确度高而忽略美学表现不足的情况。

第二，两阶段设计使评测方法本身具有演进性。

通用能力作为先导研究，承担了维度验证和问题识别功能。写实风格约束缺失、光效词汇歧义等问题，在先导研究阶段被发现并在正式研究中修正。这种设计说明评测框架不是一次性成型的静态方案，而是在实践过程中不断修正和完善的成果。

第三，评分锚点与扣分说明提供了可追溯依据。

各维度均配有明确的评分标准和分数段表现描述，低分案例配有具体扣分说明。这使得评分过程具有一定可复现性，也便于后续对争议题目进行复核。

第四，归因分析区分了不同来源的问题。

低分案例被区分为提示词设计缺陷、模型能力短板、训练数据偏差等类型，并给出了对应的改进方向。这种归因方式比单纯的分数对比更能为模型优化提供可落地的参考。

6.2 局限性

本次评测存在以下局限，需要在解读结论时予以考虑。

第一，样本量有限。

本次评测共 82 题，虽已覆盖主要能力方向，但部分维度激活样本偏少。尤其物理真实感、动态与快门感等维度，在少数题目上得分波动可能影响均分稳定性。后续应扩充题库，重点增加高区分度维度的样本量。题目设置仍有待加强，部分题目未能有效区分模型能力，尤其风景专项的准确度维度存在天花板效应，区分度不足，属于本次设计短板。人像测评侧重单人，缺少多人互动评测维度。

第二，评分主观性。

美学质量评分由单人完成，虽然依据评分锚点，但不可避免存在主观性。

后续应引入多人盲评，并计算评分者间一致性，以降低个体判断对结果的影响。

第三，模型参数不完全对齐。

Midjourney V8.2 采用 RAW 模式、风格化 100、HD，Seedream 5.0 Pro 与 Kling Image 3.0 采用 2K 默认输出。不同平台的生成策略差异无法完全消除，尤其 Midjourney V8.2 的风格化参数可能使其美学表现接近能力上限。但通用能力和准确度维度受风格化影响较小，主要结论仍有效。

第四，提示词约束密度不一致。

为接近真实使用场景，提示词约束密度并不完全统一。部分题目信息密度高，部分题目较为开放。提示词越详细，模型越容易被准确执行；提示词越开放，准确度分数可能越低。对于准确度评分为 0 的题目，已尽量复核是否由提示词信息不足导致，但这一因素仍可能对结果产生轻微影响。

第五，只评测“最优一张”，未覆盖生成稳定性。

本次评测采用“生成多张、选最优一张”的策略，反映的是模型能力上限，而非生成稳定性。如果模型在多次生成中波动较大，其真实用户体验可能低于本次评测结果。后续应增加多张平均评分或稳定性指标。

第六，版本时效性。

文生图模型迭代快速，本次结论仅针对评测时的模型版本。模型更新后，部分结论可能不再成立。

第七，模型生成数量不对等

Midjourney V8.2 网页版批量生成仅提供 1 / 2 / 4 张档位，无 3 张选项；为与 Seedream 5.0 Pro、Kling Image 3.0 的 3 张尽量对齐，本次选择 4 张档。最优一张的选择基数因此不对等（4 选 1 vs 3 选 1），理论上可能轻微抬高 Midjourney V8.2 的美学表现。

6.3 结论适用边界与使用建议

6.3.1 适用边界

本报告结论存在以下边界，超出范围可能产生偏差：

场景边界：仅覆盖风景美学、叙事感女性人像两类场景，不代表产品摄影、工业设计、多人场景、文字渲染等其他场景的表现；

能力边界：仅评测图像的指令准确度与美学质量，不代表视频生成、3D 生成、实时渲染等其他能力；

版本边界：结论仅对应评测时的模型版本，模型迭代后结论可能失效。

6.3.2 分角色使用指南

模型算法团队：重点阅读第三、四章的 Bad Case 归因，定位具体能力短板；

产品选型团队：重点参考 5.1 能力画像，结合业务场景匹配模型。

6.4 下一版改进方向

基于本次评测的经验与不足，后续可以从以下方向继续完善。

第一，引入多人盲评与一致性检验。

建立公开评测题库与评分标准，引入社区多评分者双盲评审。题目分配由系统完成（每题 ≥ 3 名评分者），题序与同题内多模型呈现顺序均按评分者独立随机化；评分者不可跳题，完成分配集后统一提交。遵循“先校准、后评分；先一致性、后结论”的原则。

1. 流程：校准轮（5 道锚定题对齐标准）→ 正式轮（每题 ≥ 3 名评分者、平衡分配、随机编号盲评、掺 2–3 道校验题剔除敷衍数据）；

2. 统计口径：美学质量 1–5 分用 ICC(A,k) 按维度计算并附 95% 置信区间；准确度 1/0 用 Fleiss' Kappa，近无变异维度以一致率代替；最终分取评分者均值；

3. 结论发布门槛（三档表）：ICC ≥ 0.6 正常发布；0.5–0.6 发布但标注“谨慎解读”； < 0.5 不出结论、补锚点复评；

第二，扩充题库，降低天花板效应。

增加高难度、多干扰项的题目，尤其在景别、光效、风格准确度等维度上设计更具区分度的样本，避免区分度不足。

第三，引入题目难度权重。

将 L1、L2、L3 或不同专项的难度差异纳入均分计算，对高难度题赋予更高权重，以更准确反映模型在压力场景下的表现。

第四，增加生成稳定性评测。

在“最优一张”之外，增加多张平均分、方差或可用率等指标，从“能力上限”和“稳定性”两个维度同时评估模型。

第五，增加中英文对照测试。

当前采用各模型最适语言策略，测的是各模型在自身最优语言环境下的能

力上限。后续可增加中英文对照测试，评估语言切换对模型表现的影响。

第六，引入客观指标辅助。

在主观评分之外，可引入美学评分模型、清晰度、噪声、构图分析等客观指标，作为主观评分的补充和交叉验证。

第七，跨版本追踪。

对同一题库进行跨版本测试，观察模型能力演进趋势，为模型迭代提供持续反馈。

附录

1-1 通用能力评测方法

1-2 通用能力评测题库

1-3 通用能力生成图片、评分、Bad Case 分析

1-4 通用能力评测结果统计（均分、可视化）

2-1 风景专项美学评测方法

2-2 风景专项美学评测题库

2-3 风景专项美学评测生成图片、评分、Bad Case 分析

2-4 风景专项美学评测结果统计（均分、可视化）

3-1 叙事感女性人像专项美学评测方法

3-2 叙事感女性人像专项美学评测题库

3-3 叙事感女性人像专项美学评测生成图片、评分、Bad Case 分析

3-4 叙事感女性人像专项美学评测结果统计（均分、可视化）

4 python 代码

附录 1-1 至 3-4 详细数据以独立 Excel 文件提供，各章节对应 Sheet 如下：

1-1 通用能力评测方法 → Sheet「1-1 通用 —— 方法」

1-2 通用能力评测题库 → Sheet「1-2 通用——题库」

.....

3-4 叙事感女性人像专项美学评测结果统计（均分、可视化）→ Sheet「3-4 人像——统计（均分、可视化）」

附录 4 以 Word 文件提供